
API 参考

发行版本 v1.0

lihetong

2025 年 12 月 27 日

内容目录:

1 介绍	3
2 模块参考	5
2.1 data_loader	5
2.2 data_clean	6
2.3 data_explore	7
2.4 model_train	8
2.5 model_evaluate	8
2.6 config	9
3 Indices and tables	11
4 项目介绍	13
4.1 功能特性	13
4.2 技术栈	13
Python 模块索引	15
索引	17

欢迎来到 EcommerceSalesAnalysis 项目文档!

这是一个电商平台销售数据分析项目，包含数据加载、清洗、探索、可视化、特征工程、模型训练和评估等模块。

CHAPTER 1

介绍

这是一个电商平台销售数据分析系统，主要功能包括：

- 数据加载与预处理
- 数据探索与分析
- 数据可视化
- 特征工程
- 模型训练与评估

CHAPTER 2

模块参考

```
data_loader  
data_clean  
data_explore  
model_train  
model_evaluate  
config
```

2.1 data_loader

Functions

<code>data_loader()</code>	从数据库中获取数据或者是从 csv 中读取数据获取数据基本结构: return: 返回原始数据
<code>get_basic_info()</code>	获取数据基本信息
<code>get_mysql_engine()</code>	获取数据库连接: return:
<code>load_from_mysql(engine, table_name)</code>	从 MySQL 读取整张表数据: param engine: 数据库: param table_name: 表名: return: DataFrame 原始数据集
<code>load_raw_data()</code>	加载原始用户数据, 并规范列名 - 读取 CSV / 数据库 - 不做任何清洗与修改 - 保证“原始性” : return: 返回加载好的原始数据
<code>save_to_mysql(df, table_name, engine)</code>	<code>load_raw_data</code> 已经清洗过列名, 去除空格, 可以正常存入先使用 if 下面的代码导入数据, 然后使用 if 判断数据没问题: param df: 原始数据: param table_name: 提前设定好的表名: param engine: 数据库
<code>table_has_data(engine, table_name)</code>	

`data_loader.data_loader() → DataFrame`

从数据库中获取数据或者是从 csv 中读取数据获取数据基本结构: return: 返回原始数据

```
data_loader.get_basic_info() → dict
    获取数据基本信息
:param df: 传入原始数据:return: 返回部分数据

data_loader.get_mysql_engine()
    获取数据库连接:return:

data_loader.load_from_mysql(engine, table_name: str) → DataFrame
    从 MySQL 读取整张表数据:param engine: 数据库:param table_name: 表名:return: DataFrame 原始数据集

data_loader.load_raw_data() → DataFrame
    加载原始用户数据, 并规范列名 - 读取 CSV / 数据库 - 不做任何清洗与修改 - 保证“原始性” :return: 返回加载好的原始数据

data_loader.save_to_mysql(df: DataFrame, table_name: str, engine)
    load_raw_data 已经清洗过列名, 去除空格, 可以正常存入先使用 if 下面的代码导入数据, 然后使用 if 判断数据没问题:param df: 原始数据:param table_name: 提前设定好的表名:param engine: 数据库

data_loader.table_has_data(engine, table_name: str) → bool
    参数
        • engine
        • table_name
    返回
```

2.2 data_clean

Functions

<code>data_clean(df, numeric_cols, categorical_cols)</code>	数据清洗主函数:return:
<code>handle_categorical_missing(df, categorical_cols)</code>	类别型特征缺失值处理: 填充为'Unknown' :param df: 原始数据集:param categorical_cols: 类别型列:param fill_value: 填充值, 默认为'Unknown' :return: 填充后的数据
<code>handle_missing_values(df, numeric_cols[, ...])</code>	数值型特征缺失值处理: 1.
<code>mark_abnormal_values(df)</code>	异常值标记 (不修改原始数值) 当前仅对 age 进行简单规则标记 - age <= 0 或 age > 100 视为异常:param df: DataFrame :return: 添加异常标记列后的 DataFrame 数据集
<code>remove_duplicates(df)</code>	重复值处理 - 统计重复行数量 - 删除完全重复的行 (保留第一条) :param df: DataFrame :return: 去重后的 DataFrame 数据集
<code>save_clean_data(df, path)</code>	保存清洗后的数据:param df: DataFrame :param path: 保存路径

```
data_clean.data_clean(df: DataFrame, numeric_cols: list, categorical_cols: list) → DataFrame
    数据清洗主函数:return:

data_clean.handle_categorical_missing(df: DataFrame, categorical_cols: list, fill_value: str = 'Unknown')
    → DataFrame
```

类别型特征缺失值处理: 填充为'Unknown' :param df: 原始数据集:param categorical_cols: 类别型列:param fill_value: 填充值, 默认为'Unknown' :return: 填充后的数据

`data_clean.handle_missing_values(df: DataFrame, numeric_cols: list, fill_value: int = -1) → DataFrame`

数值型特征缺失值处理: 1. 使用指定值 (默认 -1) 填充缺失 2. 为每个数值特征创建缺失指示变量:param df: 原始 DataFrame 数据集:param numeric_cols: 数值列:return: 填充后的数据

`data_clean.mark_abnormal_values(df: DataFrame) → DataFrame`

异常值标记 (不修改原始数值) 当前仅对 age 进行简单规则标记 - age <= 0 或 age > 100 视为异常:param df: DataFrame :return: 添加异常标记列后的 DataFrame 数据集

`data_clean.remove_duplicates(df: DataFrame) → DataFrame`

重复值处理 - 统计重复行数量 - 删除完全重复的行 (保留第一条) :param df: DataFrame :return: 去重后的 DataFrame 数据集

`data_clean.save_clean_data(df: DataFrame, path: str) → None`

保存清洗后的数据:param df: DataFrame :param path: 保存路径

2.3 data_explore

Functions

<code>analyze_feature_by_group(df, group_col, ...)</code>	分析某个特征在不同分组中的分布:param df: pandas DataFrame, 输入的数据集:param group_col:str, 分组列名 (如'lifecycle') :param feature_col:str, 要分析的特征列名:param normalize:bool, 是否计算比例而不是计数, 默认为 True (计算比例) :return:DataFrame, 交叉表显示特征在不同分组中的分布
<code>data_explore()</code> <code>explore_categorical_features(df[, top_n])</code>	展示所有探索的数据:返回: 分析类别型特征的分布情况:param df: 输入原始的数据集:param top_n:int, 显示每个类别的前 N 个值, 默认显示前 10 个:返回:字典, 键为类别型列名, 值为该列的值分布 Series
<code>explore_correlation(df[, method, threshold])</code>	分析数值特征之间的相关性:param df:DataFrame, 原始数据:param method: 相关系数计算方法 ('pearson', 'spearman', 'kendall'), 默认 pearson :param threshold: 相关性阈值, 用于筛选强相关特征对:返回: corr_matrix : 相关性矩阵 strong_corr : 强相关特征对 (DataFrame)
<code>explore_missing_values(df)</code>	统计各字段缺失率:返回:DataFrame, 包含每个字段的缺失数量和缺失率, 按缺失率降序排列
<code>explore_numeric_features(df)</code>	分析数值型特征的描述性统计:param df: 输入原始的数据集:返回:DataFrame, 包含各数值型特征的统计量 (计数、均值、标准差、最小值、25%、50%、75%、最大值)
<code>split_columns_by_type(df)</code>	自动划分数值列和类别列:param df: DataFrame 数据集:返回: 数值列和类别列

`data_explore.analyze_feature_by_group(df: DataFrame, group_col: str, feature_col: str, normalize: bool = True) → DataFrame`

分析某个特征在不同分组中的分布:param df: pandas DataFrame, 输入的数据集:param group_col:str, 分

组列名 (如'lifecycle') :param feature_col:str, 要分析的特征列名:param normalize:bool, 是否计算比例而不是计数, 默认为 True (计算比例) :return:DataFrame, 交叉表显示特征在不同分组中的分布

data_explore.**data_explore()**

展示所有探索的数据:return:

data_explore.**explore_categorical_features**(df: DataFrame, top_n: int = 10) → dict

分析类别型特征的分布情况:param df: 输入原始的数据集:param top_n:int, 显示每个类别的前 N 个值, 默认显示前 10 个:return: 字典, 键为类别型列名, 值为该列的值分布 Series

data_explore.**explore_correlation**(df: DataFrame, method: str = 'pearson', threshold: float = 0.7) → DataFrame

分析数值特征之间的相关性:param df:DataFrame, 原始数据:param method: 相关系数计算方法 ('pearson', 'spearman', 'kendall'), 默认 pearson :param threshold: 相关性阈值, 用于筛选强相关特征对:return:

corr_matrix : 相关性矩阵 strong_corr : 强相关特征对 (DataFrame)

data_explore.**explore_missing_values**(df: DataFrame) → DataFrame

统计各字段缺失率:return:DataFrame, 包含每个字段的缺失数量和缺失率, 按缺失率降序排列

data_explore.**explore_numeric_features**(df: DataFrame) → DataFrame

分析数值型特征的描述性统计:param df: 输入原始的数据集:return:DataFrame, 包含各数值型特征的统计量 (计数、均值、标准差、最小值、25%、50%、75%、最大值)

data_explore.**split_columns_by_type**(df: DataFrame)

自动划分数值列和类别列:param df: DataFrame 数据集:return: 数值列和类别列

2.4 model_train

Functions

train_model(df, target_col[, test_size, ...])

模型训练模块:param df: 特征工程后的数据:param target_col: 目标列:return: 训练好的模型 + 测试集

model_train.**train_model**(df: DataFrame, target_col: str, test_size: float = 0.2, random_state: int = 123, model_type: str = 'rf')

模型训练模块:param df: 特征工程后的数据:param target_col: 目标列:return: 训练好的模型 + 测试集

2.5 model_evaluate

Functions

evaluate_model(model, x_test, y_test)

模型评估函数

model_evaluate.**evaluate_model**(model, x_test, y_test)

模型评估函数

2.6 config

CHAPTER 3

Indices and tables

- genindex
- modindex
- search

CHAPTER 4

项目介绍

EcommerceSalesAnalysis 是一个电商平台销售数据分析项目。该项目旨在通过数据科学的方法对电商平台的销售数据进行深入分析，提供有价值的业务洞察。

4.1 功能特性

- **数据加载:** 支持多种格式的销售数据加载
- **数据清洗:** 自动识别和处理数据中的异常值、缺失值
- **数据探索:** 提供丰富的统计分析功能
- **数据可视化:** 生成直观的图表展示数据特征
- **特征工程:** 提取有用的特征用于模型训练
- **模型训练:** 使用机器学习算法预测销售趋势
- **模型评估:** 评估模型性能并提供可视化结果

4.2 技术栈

- Python 3.x
- Pandas - 数据处理
- NumPy - 数值计算
- Matplotlib/Seaborn - 数据可视化
- Scikit-learn - 机器学习
- Sphinx - 文档生成

Python 模块索引

c

config, 9

d

data_clean, 6
data_explore, 7
data_loader, 5

m

model_evaluate, 8
model_train, 8

索引

A

analyze_feature_by_group() (在 data_explore 模块中), 7

C

config
 module, 9

D

data_clean
 module, 6
data_clean() (在 data_clean 模块中), 6
data_explore
 module, 7
data_explore() (在 data_explore 模块中), 8
data_loader
 module, 5
data_loader() (在 data_loader 模块中), 5

E

evaluate_model() (在 model_evaluate 模块中), 8
explore_categorical_features() (在 data_explore 模块中), 8
explore_correlation() (在 data_explore 模块中), 8
explore_missing_values() (在 data_explore 模块中), 8
explore_numeric_features() (在 data_explore 模块中), 8

G

get_basic_info() (在 data_loader 模块中), 5
get_mysql_engine() (在 data_loader 模块中), 6

H

handle_categorical_missing() (在 data_clean 模块中), 6

handle_missing_values() (在 data_clean 模块中), 7

L

load_from_mysql() (在 data_loader 模块中), 6
load_raw_data() (在 data_loader 模块中), 6

M

mark_abnormal_values() (在 data_clean 模块中), 7
model_evaluate
 module, 8
model_train
 module, 8
module
 config, 9
 data_clean, 6
 data_explore, 7
 data_loader, 5
 model_evaluate, 8
 model_train, 8

R

remove_duplicates() (在 data_clean 模块中), 7

S

save_clean_data() (在 data_clean 模块中), 7
save_to_mysql() (在 data_loader 模块中), 6
split_columns_by_type() (在 data_explore 模块中), 8

T

table_has_data() (在 data_loader 模块中), 6
train_model() (在 model_train 模块中), 8